

李 梁

数据开发工程师

电话: 19143948881

邮箱: 19143948881@163.com

意向岗位: 数据开发工程师

到岗时间: 半个月内



教育背景

郑州轻工业大学 | 数据科学与大数据技术 (本科, 统招)

2019.09 - 2023.06

专业排名前 10% | 国家励志奖学金×1 | 一等奖学金×2 | 省级优秀毕业论文 | 社会先进个人

专业技能

- 编程语言: Python (主力)、SQL、Java、Shell
- 数据仓库: Doris / Hive / Spark 数仓 0→1 实战; 精通 Kimball 维度建模与 ODS/DWD/DWS/ADS 分层
- 性能调优: HiveSQL / SparkSQL / StarRocksSQL 复杂查询与窗口函数; 数据倾斜、Shuffle 优化、分区裁剪
- 数据集成: Scrapy-Redis 分布式采集; Kafka 流式接入、Sqoop / DataX 离线同步
- AI 数据工程: LLM 数据提取→迭代修复→整合→多级质检"全链路训练数据生产
- 数据质量: 设计格式校验→缩写映射→序列比对→多维去重→增量入库, 构建数据分级与错误追溯体系
- 工程化: Docker / K8s 部署、DolphinScheduler / Agent Flow 调度、Git、Linux
- BI 可视化: FineBI / FineReport / QuickBI, 独立完成指标设计到看板交付
- 生物信息学: 熟悉 siRNA 双链体结构与核苷酸化学修饰; BioPython 序列比对与反向互补验证

工作经历

汉克时代科技有限公司 | 数据开发工程师 2024.03 - 至今驻场服务于上海人工智能实验室 (上智院), 任 siRNA 医药大模型项目数据工程核心开发, 独立负责从专利采集到模型可用数据的全链路体系建设。

数字马力 (郑州) 信息技术有限公司 | 数据仓库工程师 2023.03 - 2024.01 独立交付横琴人寿、和兆服饰两个离线数仓项目, 覆盖选型、分层建模、ETL、治理与 BI, 分别落地 Hive+Spark 与 Doris 双栈。

项目经历

siRNA 医药大模型 — 数据工程体系建设 上海人工智能实验室 | 2024.03 - 至今项目背景: 上智院世界科学智能大赛生命科学赛道核心项目。需从全球近十年约 20 万篇专利中, 由 LLM 筛出约 2500 篇 siRNA 专利, 提取正反义链序列、化学修饰、基因靶标、实验条件与 mRNA 残留率等数据,, 构建业界首个面向药物设计的 siRNA 修饰序列数据集。

技术栈: Python | StarRocks | Redis | Kafka | Docker/K8s | Agent Flow | LLM

核心贡献

- 独立设计并落地「AI 标注 → 智能修复 → 数据整合 → 数据质检」四阶段自动化流水线, 将单篇专利处理从人工 4-6 小时压缩至分钟级, 最终从 60 万+ 候选数据中质检产出约 10 万条模型可用数据。

• 采集筛选

- 主导 Scrapy-Redis 分布式爬虫（断点续传 + 代理池 + 限速），对接 Google Patents / Lens / 欧专局三源，同族去重后零干预采集约 20 万篇专利；引入 LLM 语义识别，从中精筛约 2500 篇 siRNA 专利。

• AI 标注

- 设计“文档识别→全文扫描→逐表提取→字段对齐→语义传播”五步抽取流程，由 LLM 自动定位目标表格并将异构表头对齐至 30+ 标准字段，攻克合并单元格、跨页续表、伪表三类解析难题；**单篇处理由人工 4-6 小时降至 15-30 分钟，标注人力由 5 人压缩至 2 人复核。

• 智能修复

- 沉淀 OCR 混淆、映射错位、序列方向、宽表未拆等 **9 类错误图谱**，为每类设计“识别→修复→兜底”三段式策略；首创“试跑下游→采集质检反馈→反哺 LLM→再修复”的闭环迭代收敛机制，**数据可用率从 60-70% 提升至 90%。

• 数据整合

- 以专利维度进行表格重塑，双链 ID 作为主键通过 AI 标注输出的 csv 和 json 进行大表聚合。创建数十个 UDF 函数调整数据格式，实现高容错的自适应聚合机制。

• 数据质检

- 设计格式校验→缩写映射→序列比对→多维去重→增量入库的五步流程，同时构建数据分级、去重状态与错误追溯体系”。

• 协作沉淀

- 与业务方共同定义 70+ 个标准字段的统一命名与语义规范，覆盖序列、修饰、实验条件等全维度数据
- 持续反馈推动标注平台与资产平台的功能迭代，建立数据交付 SOP，使上下游协作效率提升约 30%。

项目成果: 20 万篇专利 → 2500 篇 siRNA 专利 → 60 万+ 结构化数据 → 约 10 万条模型可用数据，建成业界首个面向药物设计的 siRNA 修饰序列数据集。

和兆服饰离线数仓建设

和兆服饰 | 2023.09 - 2024.01

项目背景: 上海和兆服饰有限公司，旗下拥有 POLO、CARTELO、LAM 等国际品牌，全国门店 3000+。原有传统报表体系已无法满足精细化运营需求，需构建企业级数据仓库支撑营销效果评估与管理决策。

技术栈: Oracle | MySQL | Doris | FineDataLink | FineBI | FineReport

• 数仓搭建

- 以 Doris MPP 替代 Hive+Spark，免去多组件运维，部署由 2 周缩至 3 天，运维成本降低约 40%；独立完成 ODS→CDM→ADS 三层建模，建表 80+ 张覆盖销售/库存/会员/渠道四域。

• 流程优化

- 串行 ETL 重构为并行管道并配合先聚合后 JOIN、分区裁剪，**核心报表跑批 50→30 分钟（提效 40%）**，产出提前至每日 8:00 前供晨会决策。

• 决策赋能

- 交付 13 张 BI 看板（含 10 大屏 + 3 移动端），覆盖 GMV/转化/RFM/渠道 ROI；**助力营销费用节省约 15%、滞销库存降低约 20%。

• 治理监控

- 撰写数仓开发规范与数据字典统一口径，部署无人值守告警脚本，**跑批故障定位由 40 分钟缩短至 12 分钟。

项目成果: 完成数仓 0→1 搭建，Doris 选型使运维成本降低 40%；核心报表跑批效率提升 40%，产出提前至每日 8:00 前；交付 13 张 BI 看板支撑管理层决策，助力营销费用节省 15%、滞销库存降低 20%。

横琴人寿保险离线数仓

横琴人寿保险 | 2023.03 - 2023.12

项目背景: 横琴人寿保险有限公司核心业务数据分散在 Oracle（保单/理赔）与 MySQL（Hive 元数据/报表）两套异构系统中，数据孤岛严重，分析部门只能手工 SQL 取数后合并效率低下，需构建离线数仓，建立客户、产品、保单三大主题域，支撑用户画像、精细化营销与风险管控。

技术栈: Python | Oracle(湛蓝 ERP) | MySQL | Sqoop | Hive | Spark | Celeborn | QuickBI

- **异构整合**

- Sqoop 全量初始化 + T+1 增量同步至 ODS，配套 Python 三重一致性校验（行数/字段/主键），**迁移数亿条记录，准确率 99.99%、零事故**，每周为 DBA 节省约 8 小时。

- **主题建模**

- 独立交付客户/产品/保单三大主题域 ODS→DWD→DWS→ADS 全链路、50+ 宽表；按月分区减 80% 扫描、维表广播免 Shuffle、引入 Celeborn 破大表 JOIN 的 IO 瓶颈，**日增量 3.5h→2h，SLA 达标率 85%→99%。

- **业务赋能**

- 基于用户画像精准触达，季度留存率 72%→79%；理赔转为"模型初筛+人工复核"，运营效率 +20%、异常识别率 +15%；QuickBI 看板替代 30+ 张手工周报，取数提效 5 倍以上。

- **交付成果获得业务方高度认可，推动实时数仓二期立项**

- 分析团队由"等数据"转向"用数据"，取数响应由 2-3 天缩至小时级自助；成果纳入公司年度战略，推动实时数仓二期立项。

项目成果: 异构整合迁移数亿条记录、准确率 99.99% 零事故；50+ 主题宽表、SLA 85%→99%+；留存 +10%、运营效率 +20%、取数提效 5 倍。

核心优势

- **AI 数据工程全链路:** 独立打通"采集→AI 抽取→迭代修复→整合→多级质检"的训练数据生产闭环，让脏乱专利变为模型可用资产，已在上智院 siRNA 项目完整落地。
- **数据质量方法论沉淀:** 擅长将脏数据先归类成错误图谱、再为每类设计"识别-修复-兜底"策略，并以"下游反馈驱动上游修复"实现质量持续收敛，可复用于任意 ETL/数据治理场景。
- **业务驱动的技术思维:** 将正反义链互补、修饰序列还原等领域规则工程化为质检算子，具备稀缺的交叉学科实战经验。
- **高效的跨团队协作:** 与算法、产品、标注、运营等多个团队紧密协作，推动数据标准化与流程自动化，建立高效的上下游数据交付 SOP，确保数据需求从提出到交付的全流程闭环管理。
- **独立交付与抗压能力:** 多次在项目周期紧、需求变化快的情况下独立完成从方案设计到上线交付，具备在高压环境下保质保量推进项目的执行力。
- **工程规范意识:** 注重代码规范、配置化设计与文档沉淀，确保可交接、可扩展，降低维护与团队协作成本，为项目持续迭代奠定工程基础。