

李 梁

数据开发工程师

电话: 19143948881

邮箱: 19143948881@163.com

意向岗位: 数据开发工程师

到岗时间: 半个月内

学历: 本科 (统招)

郑州轻工业大学 · 数据科学与大数据技术



教育背景

- 郑州轻工业大学 | 数据科学与大数据技术 (本科, 统招)** 2019.09 - 2023.06
专业排名前10% | 国家励志奖学金×1 | 一等奖学金×2 | 省级优秀毕业论文 | 社会先进个人

专业技能

- 编程语言:** Python (主力)、SQL、Java、Shell; 熟练使用pandas/NumPy/BioPython/Scrapy等库
- 数据仓库:** Doris/Hive/Spark数仓0→1搭建经验; 熟悉Kimball维度建模与ODS/DWD/DWS/ADS分层设计
- SQL调优:** 熟练编写HiveSQL、SparkSQL、StarRocksSQL等复杂查询与窗口函数; 具备数据倾斜治理、Shuffle优化、分区裁剪等实战经验
- 数据集成:** 基于Scrapy-Redis构建过分布式采集系统; 熟悉Kafka消息队列与Sqoop/DataX离线同步
- 数据质量:** 独立设计6步DQC流水线 (格式校验→缩写映射→序列比对→智能去重→增量入库), 构建数据分级与错误追溯体系
- 工程化:** 熟悉Docker/K8s容器部署、DolphinScheduler/Agent Flow任务调度、Git版本管理与Linux命令
- BI可视化:** FineBI、FineReport、QuickBI报表与看板开发, 能独立完成从指标设计到看板交付的全流程
- 生物信息学:** 熟悉siRNA双链体结构与核苷酸化学修饰体系, 能使用BioPython进行序列比对与反向互补验证

工作经历

- 汉克时代科技有限公司 | 数据开发工程师** 2024.03 - 至今
驻场服务于**上海人工智能实验室 (上智院)**, 参与siRNA医药大模型项目。作为**数据工程核心开发**, 独立负责多源专利采集、Agent Flow自动化解析、ETL全流程开发与数据质量体系构建, 与算法、产品、标注团队紧密协作, 持续交付高质量结构化训练数据。
- 数字马力 (郑州) 信息技术有限公司 | 数据仓库工程师** 2023.03 - 2024.01
先后参与横琴人寿保险、和兆服饰两个离线数仓项目, 独立完成数仓选型、分层建模、ETL全链路开发、数据治理与BI报表支撑, 分别覆盖Hive+Spark与Doris两套技术栈。

项目经历

- siRNA医药大模型 — 数据工程体系建设** 上海人工智能实验室 | 2024.03 - 至今
项目背景: siRNA医药大模型是上智院在世界科学智能大赛生命科学赛道的核心研究项目。项目需从Google Patents、Lens、欧洲专利局三大渠道采集近十多年约20万篇全球专利, 经大语言模型识别筛选出约2500篇siRNA相关专利, 从中提取正反义链序列、化学修饰、基因靶标、实验条件与mRNA残留率等结构化数据, 构建**业界首个面向药物设计的siRNA修饰序列数据集**。

技术栈: Python | StarRocks | Redis | Kafka | Docker/K8s | 墨策平台 (Agent Flow) | BioPython

- **参与构建多源分布式专利采集平台，覆盖20万篇全球专利**

- 基于Scrapy-Redis设计分布式爬虫（断点续传+代理池+限速），对接Google Patents、Lens、欧洲专利局三大数据源
- 实现国家维度自动去重（同族专利优先保留WO），累计采集近十年约20万篇专利PDF，零人工干预
- 接入大语言模型对专利摘要与权利要求进行语义识别，从20万篇中精准筛选出**约2500篇**siRNA相关专利

- **搭建Agent Flow端到端自动化解析流程，单篇处理从数小时降至分钟级**

- 在墨策平台搭建PDF→图片转换→OCR表格识别→结构化JSON→逐表CSV→单篇合并CSV的全自动解析工作流
- 合并CSV后经人工标注补充缺失字段，输出完整结构化数据供后续ETL与质检环节消费
- 上线前单篇需人工标注**4-6小时**、5人满负荷运转；上线后自动触发，单篇缩至**15-30分钟**，仅需**2人**异常复核

- **设计配置化ETL Pipeline，将新专利接入成本从2人日降至0.5人日**

- 设计JSON驱动的动态列映射框架：每篇专利仅需一份配置文件，系统根据配置自动调用14种处理函数链式执行，完成多表JOIN、字段合并与数据标准化，彻底消除“一篇专利一套代码”的开发模式
- 新专利接入从开发+联调2个工作日缩短至**半天完成配置+验证**，团队数据生产效率提升显著

- **构建6步DQC流水线，从60万+条数据中质检产出约10万条可训练数据**

- 设计列校验→缩写拆分→反向互补验证→映射校验→智能去重→增量入库的六步质检体系，每步设有明确的错误标记与分级，不合格数据可追溯至具体失败原因
- 经全链路质检后约**10万条**数据通过全部校验直接用于模型训练，不合格数据带错误标签保留供人工复核
- 建立pre_model_flag六档数据分级体系，供算法团队按完整度灵活选择训练子集，减少算法侧数据清洗返工

- **推动数据标准化，统一70+字段映射规范**

- 主导定义70+个标准字段的统一命名与语义规范，覆盖序列、修饰、实验条件等全维度数据
- 持续反馈推动标注平台与资产平台的功能迭代，建立数据交付SOP，使上下游协作效率提升约30%

项目成果: 从三大专利源采集20万篇专利，经LLM筛选出2500篇siRNA专利，累计提取**60万+条**结构化数据，其中**约10万条**通过全部质检用于训练；构建**业界首个面向药物设计的siRNA修饰序列数据集**。

- **和兆服饰离线数仓建设**

和兆服饰 | 2023.09 - 2024.01

项目背景: 上海和兆服饰有限公司，旗下拥有POLO、CARTELO、LAM等国际品牌，全国门店3000+。原有传统报表体系已无法满足精细化运营需求，需构建企业级数据仓库支撑营销效果评估与管理决策。

技术栈: Oracle(伯俊DRP) | MySQL | Doris | FineDataLink | FineBI | FineReport

- **主导数仓0→1搭建，替代Hive+Spark方案降低40%运维成本**

- 选用Doris MPP替代Hive+Spark，免去HDFS/YARN/Spark多组件运维，部署从2周缩至3天，运维成本降低约40%
- 独立完成ODS→CDM→ADS三层建模，建表80+张覆盖销售、库存、会员、渠道四大业务域

- **优化ETL流程，核心报表跑批效率提升40%**

- 将串行ETL改为并行管道，结合SQL优化（先聚合后JOIN、分区裁剪），核心报表跑批从50分钟降至30分钟
- 报表产出时间提前至每日8:00前，管理层可在晨会前获取最新经营数据，决策响应速度显著提升

- **交付10张决策大屏+3张移动看板，直接支撑管理层数据驱动决策**

- 覆盖GMV/客单价/转化率分析、库存周转预警、会员RFM分层、渠道ROI评估等核心场景
- 看板上线后，市场部基于渠道ROI优化投放策略，营销费用节省约15%；库存预警帮助采购部将滞销库存降低约20%

- **建立数据治理规范与监控体系，跑批故障定位时间缩短70%**

- 独立撰写数仓开发规范文档，构建基于伯俊DRP的数据字典，统一上下游数据口径
- 编写实时邮件告警脚本实现无人值守监控，跑批异常平均定位时间从40分钟缩短至12分钟

项目成果: 完成数仓0→1搭建，Doris选型使运维成本降低40%；核心报表跑批效率提升40%，产出提前至每日8:00前；交付**13张BI**看板支撑管理层决策，助力营销费用节省15%、滞销库存降低20%。

- **横琴人寿保险离线数仓**

横琴人寿保险 | 2023.03 - 2023.12

项目背景: 横琴人寿保险有限公司核心业务数据分散在Oracle（保单/理赔）与MySQL（Hive元数据/报表）两套异构系统中，数据孤岛严重，分析部门长期依赖手工SQL取数且效率低下。需构建基于Hadoop生态的离线数仓，建立客户、产品、保单三大主题域，支撑用户画像、精细化营销与风险管控。

技术栈: Python | Oracle(湛蓝ERP) | MySQL | Sqoop | Hive | Spark | Celeborn | QuickBI

- **完成异构数据源整合，迁移准确率99.99%，零数据事故**

- 使用Sqoop制定并执行数据迁移方案：Oracle核心业务数据全量初始化+配置T+1增量同步至ODS层
- 编写Python自动化校验脚本（行数/字段值/主键一致性三重比对），累计迁移数亿条记录，准确率99.99%、零事故
- 迁移自动化上线后，DBA团队不再需要人工核对数据，每周节省约8人时的手工比对工作量
- **独立交付三大主题域，日增量ETL稳定在2小时窗口期内**
 - 独立完成客户、产品、保单三大主题域ODS→DWD→DWS→ADS全链路开发，产出50+张主题宽表
 - Spark作业调优：保单表按月分区减少80%扫描量；维度表广播避免Shuffle；引入Celeborn解决大表JOIN的IO瓶颈
 - 日增量作业从3.5小时压缩至2小时内，**SLA达标率从85%提升至99%+**，彻底消除了下游报表延迟出数的问题
- **数据赋能业务增长：客户留存率+10%，运营效率+20%**
 - 客户主题数据上线后，市场部基于用户画像实施精准触达策略，季度客户留存率从72%提升至79%（+10%）
 - 风控数据整合后，理赔审核从纯人工转为“模型初筛+人工复核”，运营效率提升约20%，异常理赔识别率提高15%
 - 基于QuickBI搭建核心分析看板（保单/理赔/客户/渠道），替代原有30+张手工Excel周报，取数效率提升5倍以上
- **交付成果获得业务方高度认可，推动实时数仓二期立项**
 - 数仓上线后，分析团队从“等数据”转为“用数据”，日常取数需求响应从2-3天缩短至小时级自助查询
 - 客户画像与风控数据被纳入公司年度战略重点，后续推动了实时数仓二期建设立项

项目成果：完成Oracle+MySQL异构数据源整合，累计迁移数亿条记录，准确率**99.99%**，零数据事故；独立交付客户、产品、保单三大主题域**50+张**宽表，日增量ETL SLA达标率从85%提升至99%+；数据赋能下客户留存率提升10%，运营效率提升20%，分析部门取数效率提升**5倍**以上。

核心优势

- **全链路数据工程能力：**从数据采集架构设计、ETL开发、数据质量管控到BI可视化交付，具备端到端独立交付能力，已在3个项目中独立承担从0到1的数据体系建设
- **AI+生物信息交叉背景：**在上智院siRNA医药大模型项目中积累了AI训练数据工程与生物信息学领域知识，能在数据处理中融入领域专业规则，具备市场稀缺的交叉学科实战经验
- **业务驱动的技术思维：**始终以业务价值为导向，用数据量化成果——从60万+条数据中质检产出10万条训练集，到BI看板助力营销费用节省15%，每项工作都有可衡量的业务产出
- **高效跨团队协作：**与算法、产品、标注、运营等多个团队紧密协作，推动数据标准化与流程自动化，建立高效的上下游数据交付SOP，确保数据需求从提出到交付的全流程闭环管理
- **技术选型与架构决策：**从Doris vs Hive+Spark数仓选型到分布式采集架构设计，在多个项目中独立完成技术方案论证与工程落地，兼顾性能、成本与可维护性
- **持续学习与领域适应：**面对生物信息学全新领域，快速掌握siRNA双链体结构与化学修饰体系，独立设计出支撑模型训练的6步DQC质检流水线，体现快速学习与领域迁移能力
- **独立交付与抗压能力：**多次在项目周期紧、需求变化快的情况下独立完成从方案设计到上线交付，具备在高压环境下保质保量推进项目的执行力
- **工程规范意识：**注重代码规范、配置化设计与文档沉淀，确保可交接、可扩展，降低维护与团队协作成本，为项目持续迭代奠定工程基础