

李 梁

数据开发工程师

电话: 19143948881

邮箱: 19143948881@163.com

意向岗位: 数据开发工程师

到岗时间: 半个月内

学历: 本科 (统招)

郑州轻工业大学 · 数据科学与大数据技术



教育背景

郑州轻工业大学 | 数据科学与大数据技术 (本科, 统招)

2019.09 - 2023.06

专业排名前 10% | 国家励志奖学金×1 | 一等奖学金×2 | 省级优秀毕业论文 | 社会先进个人

专业技能

- 编程语言:** Python (主力)、SQL、Java、Shell; 熟练使用 pandas/NumPy/BioPython/Scrapy 等库
- 数据仓库:** Doris/Hive/Spark 数仓 0→1 搭建经验; 熟悉 Kimball 维度建模与 ODS/DWD/DWS/ADS 分层设计
- SQL 调优:** 熟练编写 HiveSQL、SparkSQL、StarRocksSQL 等复杂查询与窗口函数; 具备数据倾斜治理、Shuffle 优化、分区裁剪等实战经验
- 数据集成:** 基于 Scrapy-Redis 构建过分布式采集系统; 熟悉 Kafka 消息队列与 Sqoop/DataX 离线同步
- 数据质量:** 五关质检体系设计 (格式→修饰还原→互补验证→靶标匹配→库比对), 构建数据分级与错误追溯体系
- 工程化:** 熟悉 Docker/K8s 容器部署、DolphinScheduler/Agent Flow 任务调度、Git 版本管理与 Linux 命令
- BI 可视化:** FineBI、FineReport、QuickBI 报表与看板开发, 能独立完成从指标设计到看板交付的全流程
- 生物信息学:** 熟悉 siRNA 双链体结构与核苷酸化学修饰体系, 能使用 BioPython 进行序列比对与反向互补验证

工作经历

汉克时代科技有限公司 | 数据工程师 2024.03 - 至今驻场服务于上海智能科学研究院, 参与 siRNA 医药大模型项目。作为**数据工程核心开发**, 独立负责多源专利采集、Agent Flow 自动化解析、ETL 全流程开发与数据质量体系构建, 与算法、产品、标注团队紧密协作, 持续交付高质量结构化训练数据。

数字马力 (郑州) 信息技术有限公司 | 数据仓库工程师 2023.03 - 2024.01 先后参与横琴人寿保险、和兆服饰两个离线数仓项目, 独立完成数仓选型、分层建模、ETL 全链路开发、数据治理与 BI 报表支撑, 分别覆盖 Hive+Spark 与 Doris 两套技术栈。

项目经历

siRNA 医药大模型 — 数据工程体系建设 上海智能科学研究院 | 2024.03 - 至今**项目背景:** siRNA 医药大模型是上海智能科学研究院在世界科学智能大赛生命科学赛道的核心研究项目。项目需从 Google Patents、Lens、欧洲专利局三大渠道采集近十多年约 20 万篇全球专利, 经大语言模型识别筛选出约 2500 篇 siRNA 相关专利, 从中提取正反义链序列、化学修饰、基因靶标、实验条件与 mRNA 残留率等结构化数据, 构建**业界首个面向药物设计的 siRNA 修饰序列数据集**。

技术栈: Python | StarRocks | Redis | Kafka | Docker/K8s | 墨策平台 (Agent Flow) | BioPython

参与构建多源分布式专利采集平台, 覆盖 20 万篇全球专利

- 基于 Scrapy-Redis 设计分布式爬虫 (断点续传+代理池+限速), 对接 Google Patents、Lens、欧洲专利局三大数据源

- 实现国家维度自动去重（同族专利优先保留 WO），累计采集近十年约 20 万篇专利 PDF，零人工干预
- 接入大语言模型对专利摘要与权利要求进行语义识别，从 20 万篇中精准筛选出约 2500 篇 siRNA 相关专利

- **搭建 Agent Flow 端到端自动解析流程，单篇处理从数小时降至分钟级**

- 在墨策平台搭建 PDF→图片转换→OCR 表格识别→结构化 JSON→逐表 CSV→单篇合并 CSV 的全自动解析 workflow
- 合并 CSV 后经人工标注补充缺失字段，输出完整结构化数据供后续 ETL 与质检环节消费
- 上线前单篇需人工标注 4-6 小时、5 人满负荷运转；上线后自动触发，单篇缩至 15-30 分钟，仅需 2 人异常复核

- **设计配置化 ETL Pipeline，将新专利接入成本从 2 人日降至 0.5 人日**

- 设计 JSON 驱动的动态列映射框架：每篇专利仅需一份配置文件，系统根据配置自动调用 14 种处理函数链式执行，完成多表 JOIN、字段合并与数据标准化，彻底消除“一篇专利一套代码”的开发模式
- 新专利接入从开发+联调 2 个工作日缩短至半天完成配置+验证，团队数据生产效率提升显著

- **构建 6 步 DQC 流水线，从 60 万+条数据中质检产出约 10 万条可训练数据**

- 设计列校验→缩写拆分→反向互补验证→映射校验→智能去重→增量入库的六步质检体系，每步设有明确的错误标记与分级，不合格数据可追溯至具体失败原因
- 经全链路质检后约 10 万条数据通过全部校验直接用于模型训练，不合格数据带错误标签保留供人工复核
- 建立 pre_model_flag 六档数据分级体系，供算法团队按完整度灵活选择训练子集，减少算法侧数据清洗返工

- **推动数据标准化，统一 70+ 字段映射规范**

- 主导定义 70+ 个标准字段的统一命名与语义规范，覆盖序列、修饰、实验条件等全维度数据
- 持续反馈推动标注平台与资产平台的功能迭代，建立数据交付 SOP，使上下游协作效率提升约 30%

项目成果: 从三大专利源采集 20 万篇专利，经 LLM 筛选出 2500 篇 siRNA 专利，累计提取 60 万+条结构化数据，其中约 10 万条通过全部质检用于训练；构建业界首个面向药物设计的 siRNA 修饰序列数据集。

- **和兆服饰离线数仓建设**

和兆服饰 | 2023.09 - 2024.01 **项目背景:** 上海和兆服饰有限公司，旗下拥有 POLO、CARTELO、LAM 等国际品牌，全国门店 3000+。原有传统报表体系已无法满足精细化运营需求，需构建企业级数据仓库支撑营销效果评估与管理决策。

技术栈: Oracle(伯俊 DRP) | MySQL | Doris | FineDataLink | FineBI | FineReport

- **主导数仓 0→1 搭建，替代 Hive+Spark 方案降低 40% 运维成本**

- 选用 Doris MPP 替代 Hive+Spark，免去 HDFS/YARN/Spark 多组件运维，部署从 2 周缩至 3 天，运维成本降低约 40%
- 独立完成 ODS→CDM→ADS 三层建模，建表 80+ 张覆盖销售、库存、会员、渠道四大业务域

- **优化 ETL 流程，核心报表跑批效率提升 40%**

- 将串行 ETL 改为并行管道，结合 SQL 优化（先聚合后 JOIN、分区裁剪），核心报表跑批从 50 分钟降至 30 分钟
- 报表产出时间提前至每日 8:00 前，管理层可在晨会前获取最新经营数据，决策响应速度显著提升

- **交付 10 张决策大屏+3 张移动看板，直接支撑管理层数据驱动决策**

- 覆盖 GMV/客单价/转化率分析、库存周转预警、会员 RFM 分层、渠道 ROI 评估等核心场景
- 看板上线后，市场部基于渠道 ROI 优化投放策略，营销费用节省约 15%；库存预警帮助采购部将滞销库存降低约 20%

- **建立数据治理规范与监控体系，跑批故障定位时间缩短 70%**

- 独立撰写数仓开发规范文档，构建基于伯俊 DRP 的数据字典，统一上下游数据口径
- 编写实时邮件告警脚本实现无人值守监控，跑批异常平均定位时间从 40 分钟缩短至 12 分钟

项目成果: 完成数仓 0→1 搭建，Doris 选型使运维成本降低 40%；核心报表跑批效率提升 40%，产出提前至每日 8:00 前；交付 13 张 BI 看板支撑管理层决策，助力营销费用节省 15%、滞销库存降低 20%。

- **横琴人寿保险离线数仓**

横琴人寿保险 | 2023.03 - 2023.12 **项目背景:** 横琴人寿保险有限公司核心业务数据分散在 Oracle（保单/理赔）与 MySQL（Hive 元数据/报表）两套异构系统中，数据孤岛严重，分析部门长期依赖手工 SQL 取数且效率低下。需构建基于 Hadoop 生态的离线数仓，建立客户、产品、保单三大主题域，支撑用户画像、精细化营销与风险管控。

- **完成异构数据源整合，迁移准确率 99.99%，零数据事故**

- 使用 Sqoop 制定并执行数据迁移方案：Oracle 核心业务数据全量初始化+配置 T+1 增量同步至 ODS 层
- 编写 Python 自动化校验脚本（行数/字段值/主键一致性三重比对），累计迁移数亿条记录，准确率 99.99%、零事故
- 迁移自动化上线后，DBA 团队不再需要人工核对数据，每周节省约 8 人时的手工比对工作量

- **独立交付三大主题域，日增量 ETL 稳定在 2 小时窗口期内**

- 独立完成客户、产品、保单三大主题域 ODS→DWD→DWS→ADS 全链路开发，产出 50+张主题宽表
- Spark 作业调优：保单表按月分区减少 80%扫描量；维度表广播避免 Shuffle；引入 Celeborn 解决大表 JOIN 的 IO 瓶颈
- 日增量作业从 3.5 小时压缩至 2 小时内，**SLA 达标率从 85%提升至 99%+**，彻底消除了下游报表延迟出数的问题

- **数据赋能业务增长：客户留存率+10%，运营效率+20%**

- 客户主题数据上线后，市场部基于用户画像实施精准触达策略，季度客户留存率从 72%提升至 79%（+10%）
- 风控数据整合后，理赔审核从纯人工转为“模型初筛+人工复核”，运营效率提升约 20%，异常理赔识别率提高 15%
- 基于 QuickBI 搭建核心分析看板（保单/理赔/客户/渠道），替代原有 30+张手工 Excel 周报，取数效率提升 5 倍以上

- **交付成果获得业务方高度认可，推动实时数仓二期立项**

- 数仓上线后，分析团队从“等数据”转为“用数据”，日常取数需求响应从 2-3 天缩短至小时级自助查询
- 客户画像与风控数据被纳入公司年度战略重点，后续推动了实时数仓二期建设立项

项目成果: 完成 Oracle+MySQL 异构数据源整合，累计迁移数亿条记录，准确率 **99.99%**，零数据事故；独立交付客户、产品、保单三大主题域 **50+张**宽表，日增量 ETL SLA 达标率从 85%提升至 99%+；数据赋能下客户留存率提升 10%，运营效率提升 20%，分析部门取数效率提升 **5 倍**以上。

核心优势

- **全链路数据工程能力:** 从数据采集架构设计、ETL 开发、数据质量管控到 BI 可视化交付，具备端到端独立交付能力，已在 3 个项目中独立承担从 0 到 1 的数据体系建设
- **AI+生物信息交叉背景:** 在上海智能科学研究院 siRNA 医药大模型项目中积累了 AI 训练数据工程与生物信息学领域知识，能在数据处理中融入领域专业规则，具备市场稀缺的交叉学科实战经验
- **业务驱动的技术思维:** 始终以业务价值为导向，用数据量化成果——从 60 万+条数据中质检产出 10 万条训练集，到 BI 看板助力营销费用节省 15%，每项工作都有可衡量的业务产出
- **高效跨团队协作:** 与算法、产品、标注、运营等多个团队紧密协作，推动数据标准化与流程自动化，建立高效的上下游数据交付 SOP，确保数据需求从提出到交付的全流程闭环管理
- **技术选型与架构决策:** 从 Doris vs Hive+Spark 数仓选型到分布式采集架构设计，在多个项目中独立完成技术方案论证与工程落地，兼顾性能、成本与可维护性
- **持续学习与领域适应:** 面对生物信息学全新领域，快速掌握 siRNA 双链体结构与化学修饰体系，独立设计出支撑模型训练的 6 步 DQC 质检流水线，体现快速学习与领域迁移能力
- **独立交付与抗压能力:** 多次在项目周期紧、需求变化快的情况下独立完成从方案设计到上线交付，具备在高压环境下保质保量推进项目的执行力
- **工程规范意识:** 注重代码规范、配置化设计与文档沉淀，确保可交接、可扩展，降低维护与团队协作成本，为项目持续迭代奠定工程基础